

Normalformen

Eine kontextfreie Grammatik $G = (V, \Sigma, R, S)$ heißt in *Chomsky Normalform*, falls alle Produktionsregeln in R eine der beiden folgenden Formen haben:

$$A \rightarrow \sigma \quad \text{für ein } \sigma \text{ aus } \Sigma$$

$$A \rightarrow BC \quad \text{für } B, C \in V$$

Syntaxbäume sind „bis auf die letzten Schritte“ binär.

Beispiel einer Transformation in Chomsky Normalform:

$$S \rightarrow aACa$$

$$A \rightarrow B \mid a$$

$$B \rightarrow C \mid c$$

$$C \rightarrow cC \mid \varepsilon$$

Elimination von ε -Regeln ($U \rightarrow \varepsilon$):

$$S \rightarrow aACa$$

$$A \rightarrow B \mid a$$

$$B \rightarrow C \mid c$$

$$C \rightarrow cC \mid \varepsilon$$

$$S \rightarrow aACa \mid aCa \mid aAa \mid aa$$

$$A \rightarrow B \mid a$$

$$B \rightarrow C \mid c$$

$$C \rightarrow cC \mid c$$

Elimination von Kettenregeln ($U \rightarrow W$):

$$S \rightarrow aACa \mid aCa \mid aAa \mid aa$$

$$A \rightarrow B \mid a$$

$$B \rightarrow C \mid c$$

$$C \rightarrow cC \mid c$$

$$S \rightarrow aACa \mid aCa \mid aAa \mid aa$$

$$A \rightarrow cC \mid c \mid a$$

$$B \rightarrow cC \mid c$$

$$C \rightarrow cC \mid c$$

Elimination nichtisolierter Terminalsymbole

$$S \rightarrow aACa \mid aAa \mid aCa \mid aa$$

$$A \rightarrow a \mid c \mid cC$$

$$B \rightarrow c \mid cC$$

$$C \rightarrow c \mid cC$$

$$S \rightarrow T_aACT_a \mid T_aAT_a \mid T_aCT_a \mid T_aT_a$$

$$A \rightarrow a \mid c \mid T_cC$$

$$B \rightarrow c \mid T_cC$$

$$C \rightarrow c \mid T_cC$$

$$T_a \rightarrow a$$

$$T_c \rightarrow c$$

und langer rechter Seiten:

$$\begin{aligned}
S &\rightarrow T_aACT_a \mid T_aAT_a \mid T_aCT_a \mid T_aT_a \\
&\vdots \\
T_c &\rightarrow c
\end{aligned}$$

$$\begin{aligned}
S &\rightarrow T_aS_1 \mid T_aS_3 \mid T_aS_4 \mid T_aT_a \\
S_1 &\rightarrow AS_2 \\
S_2 &\rightarrow CT_a \\
S_3 &\rightarrow AT_a \\
S_4 &\rightarrow CT_a \\
A &\rightarrow a \mid c \mid T_cC \\
B &\rightarrow c \mid T_cC \\
C &\rightarrow c \mid T_cC \\
T_a &\rightarrow a \\
T_c &\rightarrow c
\end{aligned}$$

Transformation allgemein:

Elimination von ε -Regeln:

Sei $G = (V, \Sigma, R, S)$ eine kontextfreie Grammatik mit $\varepsilon \notin L(G)$.

Sei $V_\varepsilon = \{A \in V \mid A \Rightarrow_G^* \varepsilon\}$. Wir streichen alle Regeln der Form $T \rightarrow \varepsilon$ und fügen für jede Regel der Form $U \rightarrow vEw$ mit $E \in V_\varepsilon$ und $vw \neq \varepsilon$ eine Regel $U \rightarrow vw$ ein.

Falls es auf einer rechten Seite mehrere Vorkommen von Variablen aus V_ε gibt, so müssen wir für alle möglichen Kombinationen dieser Variablen neue Regeln einführen.

Elimination von Kettenregelzyklen:

Sei $G = (V, \Sigma, R, S)$ eine kontextfreie Grammatik ohne ε -Regeln.

Falls es eine Menge von Variablen T_1, \dots, T_k mit $T_1 \rightarrow T_2, \dots, T_{k-1} \rightarrow T_k$ und $T_k \rightarrow T_1$ gibt, ersetzen wir alle Vorkommen von T_1, \dots, T_k durch eine einzige neue Variable T .

Elimination von Kettenregeln:

Sei $G = (V, \Sigma, R, S)$ eine kontextfreie Grammatik ohne ε -Regeln und Kettenregelzyklen.

Da es keine Kettenregelzyklen gibt, können wir die Variablen so bezeichnen, dass $V = \{A_1, \dots, A_n\}$ und aus $A_i \rightarrow A_j$ folgt, dass $i < j$.

Wir gehen die Regeln für $k = n - 1, \dots, 1$ durch:

Falls es eine Regel $A_k \rightarrow A_{k'}$ mit $k' > k$ gibt mit Regeln

$$A_{k'} \rightarrow \alpha_1 \mid \dots \mid \alpha_m$$

streichen wir $A_k \rightarrow A_{k'}$ und fügen die Regeln

$$A_k \rightarrow \alpha_1 \mid \dots \mid \alpha_m$$

hinzu.

Elimination von nichtisolierten Terminalsymbolen auf rechten Seiten:

Sei $G = (V, \Sigma, R, S)$ eine kontextfreie Grammatik ohne ε -Regeln und Kettenregeln.

Bei jeder Regel, die ein Terminalsymbol σ auf einer rechten Seite der Länge mindestens zwei enthält, ersetzen wir das Terminalsymbol durch eine neue Variable T_σ und fügen die Regel $T_\sigma \rightarrow \sigma$ hinzu.

Elimination von langen rechten Seiten:

Sei $G = (V, \Sigma, R, S)$ eine kontextfreie Grammatik, bei der alle Regel von der Form $A \rightarrow \sigma$ mit $\sigma \in \Sigma$ oder von der Form

$$A \rightarrow B_1 B_2 \cdots B_k$$

sind.

Falls bei einer Regel der zweiten Form $k \geq 3$ ist, führen wir neue Variablen C_2, \dots, C_{k-1} ein und ersetzen die Regel durch

$$\begin{array}{rcl} A & \rightarrow & B_1 C_2 \\ C_2 & \rightarrow & B_2 C_3 \\ & \vdots & \\ C_{k-1} & \rightarrow & B_{k-1} B_k \end{array}$$

Zwei Grammatiken G und G' heißen *äquivalent* genau dann wenn $L(G') = L(G)$.

Satz:

Sei G eine kontextfreie Grammatik mit $\varepsilon \notin L(G)$. Dann gibt es eine äquivalente kontextfreie Grammatik G' in Chomsky Normalform.

Beweisskizze: Transformiere G wie oben beschrieben in eine kontextfreie Grammatik G' in Chomsky Normalform. Dann gilt $L(G') = L(G)$.



Eine kontextfreie Grammatik $G = (V, \Sigma, R, S)$ heißt in (strenger) *Greibach Normalform*, falls $R \subseteq V \times \Sigma V^*$, d.h., alle Produktionsregeln haben die Form

$$A \rightarrow \sigma B_1 B_2 \dots B_k$$

für ein $\sigma \in \Sigma$, $k \geq 0$ und $B_1, B_2, \dots, B_k \in V$.

Satz:

Sei G eine kontextfreie Grammatik mit $\varepsilon \notin L(G)$. Dann gibt es eine äquivalente kontextfreie Grammatik G' in Greibach Normalform.